

KAMP CN7·RG3 — 현재 코드 구성과 흐름

2026-10-03 기준 · D:\workspace\kamp · 작성: Claude (Codex 구현 기반 + Claude 판정 계층 최종본)

한 줄 요약


Codex가 만든 7단계 운영 파이프라인 위에 데이터 유형별 판정 계층을 얹었다. **CN7**은 랜덤 포레스트 + 검사 예산 (배치 상위 10% 검사), **RG3**는 드리프트 기반 판단 불확실 단계(높음·중간·낮음)로 운영한다. 현재 코드는 이 수준에서 마감하며, 남은 항목은 아래 7장의 결정(Claude 권고)으로 정리한다.

1. 프로젝트 구성

위치	역할	작성
02.preprocessing/	입력 검증, 24개 값 완전 일치 패턴 통합(라벨 = max), 고정 Test 20% + 개발 4-fold 분할	Codex
03.modeling/models/	IF·OCSVM 노트북, LR 탐색 (logistic_regression.py, 240설정×1,001임계값), RF 매뉴얼	Codex
03.modeling/common/pipeline_runtime.py	7단계 운영 기반: 배치 전처리·추론·드리프트·모델별 재학습(CT)·평가/승격/롤백(CD)	Codex (보존)
03.modeling/common/decision_runtime.py	데이터 유형별 판정 계층: CN7 검사 예산, RG3 불확실 단계·구간, 중복 배치 차단, 잠금 관리	Codex 초안 → Claude 최종
03.modeling/pipeline_cli.py	운영 명령 진입점(ingest, retrain, evaluate, promote, rollback, select-cn7, unlock 등)	Codex + Claude
03.modeling/04_operations.ipynb	운영 상태·최근 배치 판단 결과 조회(읽기 전용)	Codex + Claude
03.modeling/tests/	통합 검증 run_checks.py (61개 테스트 + LR 재검산), 실제 자료 예시 리포트	Codex + Claude
runtime/{cn7,rg3}/	등록 모델·운영 포인터·배치·드리프트·평가 이력	실행 산출물

설계 원칙: pipeline_runtime.py 는 수정하지 않는다(LR 실행 기록의 코드 해시가 깨지지 않도록). 보완은 이를 상속한 decision_runtime.py 에서 처리한다.

2. 전체 흐름



단계별 핵심 동작

단계	동작
2 패턴 전처리	24개 입력이 완전히 같은 행을 한 패턴으로 묶고, 한 번이라도 불량이면 위험 이력 패턴(1). 원본 ID·제품 빈도·원본 연결 보존. CN7 1,211행→606패턴(위험 14), RG3 1,182행→591패턴(위험 25, 전부 정상과 공존)
3 초기 모델	IF·OCSVM은 정상 패턴만, LR·RF는 정상·위험 전체로 학습. 변환(scaler·PCA·상수 제거)은 학습 구간에 서만 적합. 개발 OOF로 선택, Test는 후속 평가만
4 배치 추론	좌표 정합 선언 없으면 보류. 저장된 변환으로 추론(재적합 없음). 같은 내용·같은 제품 ID 배치 재전송은 보류
5 드리프트	값별·분위 구간별·변수 조합별 비율과 같은 모델 버전 점수 분포의 변화량(TV 거리). 제품 200·고유 패턴 40 미만이면 누적 대기. 1회 초과 watch, 2회 연속 review
6 CT	review 상태·원인 기록·라벨 배치가 있어야 실행. 기존 위험 이력을 신규 정상으로 덮어쓰지 않음(max 재 집계). Test·평가 패턴 학습 차단. 비라벨은 재학습 제외
7 CD	현재 모델과 후보를 같은 독립 평가 자료로 비교. 표본 부족·이미 본 자료·기준 미달이면 유지. 통과한 모델 만 개별 교체, 이전 버전 롤백 가능. 해시로 변조 감지

3. 데이터 유형 분기 — 왜 CN7과 RG3를 다르게 다루나

개발 데이터 4-fold OOF에서 단순 구간 위험 점수가 위험 패턴을 무작위보다 잘 순위화하는지 순열 검정을 했다(Test 미 사용).

데이터	OOF AUC	순열 p값	상위 10% 검사 시 위험 발견	분기
CN7	0.870	0.001	11개 중 4개	모델 판정
RG3	0.451	0.776	20개 중 1개 (무작위 기대 약 2개)	분포 감시

4. CN7 — 랜덤 포레스트 + 검사 예산

모델 선택 근거 (개발 OOF, 위험 11개)

모델	OOF AUC	상위 5%	상위 10%	상위 20%
RF (운영 고정 설정)	0.940	5	9	11
LR (튜닝 설정)	0.882	6	8	9
OCSVM (선택 설정)	0.798	4	4	7

- 고정 임계값 방식은 세 모델 모두 Test 위험 3건을 전부 놓쳤다. 순위는 맞는데(AUC 약 0.9) 임계값이 실패한 것이므로 **순위 기반 검사 예산**으로 판정한다.
- 배치마다 RF 점수 상위 10% 제품을 검사 대상으로 표시한다. 경계 동점은 모두 포함.
- 모델 교체: 같은 평가 자료·같은 검사량에서 위험을 더 많이 찾아야 하고, 예산 내 최대 발견 가능 수의 50% 이상이어야 한다.
- 선정에 쓴 평가 자료로는 승격할 수 없다(선택 편향 차단).

5. RG3 — 드리프트 기반 판단 불확실 구간

단계	조건	안내
높음	드리프트 review(2회 연속 변화) 또는 학습 범위 밖 값	추가 검사 권고 (review면 배치 전체), 원인 확인
중간	드리프트 watch(1회 변화) 또는 정보 부족	관찰·샘플 검사 유지
낮음	위 해당 없음	관찰 (정상 보증 아님)
참고	과거 위험 이력이 평균보다 높게 관측된 구간	표시만 함 (예측력 미검증)

- 배치마다 분포가 가장 많이 바뀐 변수·조합 상위 8개를 "불확실 구간"으로 제시한다.
- 기존 Test 119개 적용 예: 재검사 권고 6, 참고 표시 58, 관찰 55 (Codex 초안 규칙은 119개 전부 재검사였다).
- 이 단계는 **모델·참조 자료가 판단할 수 없는 정도**이며 불량 위험도·불량 확률이 아니다.

6. 검증 상태

테스트	내용	결과
test_operations	배치·드리프트·4종 CT·CD·롤백·거부 조건 (합성 자료)	12/12
test_registration_and_logistic	후보 등록 감사, LR 변환·임계값, 노트북 코드 동기화	8/8
test_existing_ocsvm	OCSVM 노트북 내장 회귀 × 데이터 × 학습 순서	24/24
test_decision_runtime	CN7 검사 예산, RG3 불확실 단계, 중복 차단, 선정/승격 분리, 잠금	17/17
audit_logistic_runs	LR 240,240행 재집계·선택·OOF·Test 예측 재현	통과

실행 환경: Claude 클라우드(Python 3.11 / scikit-learn 1.8). 원본 데이터·runtime·LR 결과는 작업 전후 동일. 사용자 PC(Python 3.14 / scikit-learn 1.9.0)에서 `run_checks.py` 1회 재실행으로 최종 확인한다. 합성 자료 테스트는 기술 검증이며 현장 성능 검증이 아니다.

7. 남은 항목 — Claude 권고 결정

항목	권고 결정	이유
CN7 검사 비율	10%로 확정	개발 OOF에서 RF가 10%로 11개 중 9개, 20%로 전부 발견. 5%는 절반 수준. 검사 여력이 허용되면 20%를 상한 대안으로 둔다.
최소 발견 비율	0.5 유지	평가 위험 수가 적은(5~10개) 상황에서 더 높이면 표본 흔들림만으로 탈락한다.
CN7 운영 모델	RF를 기준 모델로 지정	<code>initial --kind rf</code> → <code>initialize</code> . 사유에는 "개발 OOF 검사 예산 근거, 독립 검증 전 비교 기준"이라고 명시한다. LR은 설명용 보조로 유지.
CN7 최종 확정	보류, 새 라벨 자료 2묶음 확보	선정용·승격용 평가 자료(각 위험 5개 이상)가 있어야 한다. 그 전까지 보고서에서는 "1순위 후보"로 표현한다.
RG3 위험 이력 재검사	끔(기본값 유지)	개발·Test 모두 예측력이 확인되지 않았다. 커먼 경보가 많아지고 신뢰가 떨어진다.
RG3 추가 개선	대회 측 문의 후 진행	생산 순서·라벨 의미가 확인되면 직전 샷 대비 변화량 특징을 시험한다. 확인 전에는 분포 감시만 운영한다.
드리프트 경보선	현행 유지 (부트스트랩 99%, 2회 연속)	현장 시계열 보정 자료가 없다. 실제 배치가 쌓이면 오경보율로 재보정한다.
비라벨 데이터	감시·추론 전용	라벨·비라벨 좌표계가 따로 표준화되어 있고, pseudo-label 재학습은 성능을 떨어뜨렸다(CN7 OOF F1 0.50→0.18).
추가 모델 튜닝	하지 않음	3개 모델·수천 설정에서 같은 양상이 반복됐다. 한계는 데이터 정보량이며, Test를 보고 조정하면 결과가 오염된다.

8. 실행 방법 (프로젝트 루트)

```
python 03.modeling/tests/run_checks.py # 전체 검증 (61개 + LR 재검산)
python 03.modeling/tests/report_decision_examples.py # 데이터 유형 판정·CN7 3모델 비교·RG3 예시

python 03.modeling/pipeline_cli.py --dataset cn7 initial --kind rf
python 03.modeling/pipeline_cli.py --dataset cn7 initialize --version <RF버전> --reason <사유>
python 03.modeling/pipeline_cli.py --dataset cn7 --inspection-fraction 0.1 ingest --input
batch.csv --coordinates-confirmed
python 03.modeling/pipeline_cli.py --dataset rg3 ingest --input batch.csv --coordinates-confirmed
python 03.modeling/pipeline_cli.py --dataset <cn7|rg3> unlock --reason <사유> # 작업 중단으로 잠금
이 남았을 때
```

9. 보고서에서 지켜야 할 표현

- 라벨 1은 "위험 이력 패턴"이다. 개별 제품의 불량 확률이 아니다.
- OOF 점수는 선택에 쓴 튜닝 점수이며 독립 일반화 성능이 아니다. Test는 이미 여러 번 본 후속 평가다.
- CN7: "RF가 같은 검사량에서 가장 많이 찾았다(개발 OOF)"까지가 근거. 운영 성능 확정은 새 자료 이후.
- RG3: "현재 입력으로 구분 근거가 없음을 확인하고, 판단할 수 없는 조건을 알리는 안전장치를 만들었다."