

F1 Score의 의미와 계산 원리

사출성형 불량 예측을 위한 평가 지표 설명서

F1 Score는 불량이라고 예측한 결과의 정확성과 실제 불량을 찾아내는 능력을 함께 평가하는 지표다. 이번 데이터에 서는 불량을 양성(Positive, 1), 양품을 음성(Negative, 0)으로 정의한다. F1은 0~1 사이의 값이며 높을수록 좋다.

혼동행렬로 예측 결과 구분하기

실제 상태 / 예측	불량으로 예측	양품으로 예측
실제 불량 1	TP · 찾아낸 불량	FN · 놓친 불량
실제 양품 0	FP · 잘못 지목한 양품	TN · 올바르게 판정한 양품

FP는 불필요한 검사나 재확인으로 이어질 수 있다. FN은 불량을 검사 우선순위에서 놓치는 경우다. 두 오류가 현장에 미치는 영향은 서로 다르다.

정밀도와 재현율은 분모가 다르다

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}$$

정밀도 Precision: 불량이라고 예측한 제품 중 실제 불량률의 비율이다. “검사 대상으로 지목한 제품이 얼마나 믿을 만 한가?”에 답한다.

재현율 Recall: 실제 불량 중 모델이 찾아낸 비율이다. “불량을 얼마나 놓치지 않았는가?”에 답한다.

F1은 두 지표의 조화평균이다

$$F_1 = \frac{2PR}{P + R} = \frac{2TP}{2TP + FP + FN}$$

P는 Precision, R은 Recall이다. P와 R이 모두 양수이면 $F1=2/(1/P+1/R)$ 로도 표현할 수 있다.

정밀도	재현율	단순 평균	F1
90%	10%	50%	18%
50%	50%	50%	50%

정밀도 90%, 재현율 10%인 모델은 지목한 불량은 잘 맞하지만 실제 불량률의 90%를 놓친다. 조화평균은 한쪽만 높은 모델에 낮은 점수를 주어 이 불균형을 드러낸다.

F1은 전체 정답 비율(Accuracy)이 아니다. TN은 F1 공식에 직접 들어가지 않으므로 양품을 많이 맞혔다는 사실만으로 F1이 높아지지 는 않는다.

실제 데이터 규모로 계산해 보기

업로드한 라벨 데이터는 총 2,393행이며 양품 2,351행, 불량 42행이다. 아래 예측 결과는 이 규모를 사용한 설명용 가상 예시이며, 모델을 실제로 학습한 결과가 아니다.

불량으로 지목한 50개 중 30개가 실제 불량이라면

실제 상태 / 예측	불량 예측	양품 예측	합계
실제 불량	TP = 30	FN = 12	42
실제 양품	FP = 20	TN = 2,331	2,351
합계	50	2,343	2,393

$$P = \frac{30}{30+20} = 0.60, \quad R = \frac{30}{30+12} \approx 0.7143$$

정밀도 60%는 불량이라고 지목한 10개 중 6개가 실제 불량이라는 뜻이다. 재현율 71.43%는 전체 불량 42개 중 30개를 찾아냈다는 뜻이다.

$$F_1 = \frac{2 \times 30}{2 \times 30 + 20 + 12} = \frac{60}{92} \approx 0.6522$$

F1은 약 0.6522, 백분율로 65.22%다. 전체 제품 중 65.22%를 맞췄다는 뜻이 아니다. 이 예시의 전체 정답 비율은 $(30+2,331)/2,393 \approx 98.66\%$ 로 별개의 값이다.

모든 제품을 양품이라고 예측하면 어떻게 될까

$$\text{Accuracy} = \frac{2351}{2393} \approx 98.24\%, \quad F_1 = \frac{0}{0+0+42} = 0$$

불량이 약 1.76%에 불과하므로, 아무 불량도 찾지 못하는 모델도 정확도는 98.24%다. 반면 불량 F1은 0이어서 이 모델의 문제를 드러낸다. 불량 예측이 하나도 없을 때 정밀도는 분모가 0으로 정의되지 않으므로, 계산 도구의 처리 규칙을 명시해야 한다.

비슷한 F1도 서로 다른 운영 결과를 뜻할 수 있다

가상 모델	TP / FP / FN	Precision	Recall	F1
A	30 / 20 / 12	60.00%	71.43%	65.22%
B	36 / 33 / 6	52.17%	85.71%	64.86%

A의 F1이 조금 높지만 B는 놓친 불량을 12개에서 6개로 줄인다. 대신 불량 후보가 50개에서 69개로 늘어난다. 불량 미탐 비용과 검사 여력에 따라 현장에서는 B를 선택할 수도 있다.

데이터 건수 출처: 업로드된 moldset_labeled_cn7.csv와 moldset_labeled_rg3.csv의 합계. 예시 A·B는 지표 해석용이며 성능 비교의 증거로 제출하면 안 된다.

대회에서 F1을 사용하는 방법

판정 임계값이 바뀌면 F1도 바뀐다

$$\hat{y} = \mathbf{1}[\hat{p} \geq \tau]$$

LR이나 RF가 출력한 불량 확률 추정값이 임계값 τ 이상이면 불량으로 분류한다. 같은 모델이라도 τ 를 바꾸면 TP·FP·FN과 F1이 달라진다. 0.5가 항상 최선인 것은 아니다.

변경	불량 후보 수	일반적인 영향
임계값을 낮춤	늘어나거나 같음	재현율은 높아지거나 같음. 오탐이 늘 수 있으며 정밀도는 보장되지 않음.
임계값을 높임	줄어들거나 같음	미탐이 늘 수 있음. 정밀도가 반드시 높아지는 것은 아님.

One-Class SVM은 불량 확률 대신 이상 점수에 임계값을 적용한다. 이상 점수가 클수록 불량 후보가 되도록 방향을 맞춘 뒤 0/1 예측을 만들면 동일한 F1 공식으로 비교할 수 있다.

검증으로 선택하고 테스트로 평가한다

1. 동일 공정 패턴이 학습과 평가 양쪽에 들어가지 않도록 그룹 분할한다.
2. 검증 또는 그룹 OOF 예측에서 임계값별 F1·Recall·FP·검사량을 계산한다.
3. 선택 기준을 미리 정한다. 예: F1 최대화, 또는 검사 예산 안에서 재현율 최대화.
4. 모델과 임계값을 고정한 뒤 잠근 테스트에서 한 번 평가한다.

테스트 F1을 보며 임계값이나 변수를 바꾸면 테스트가 사실상 검증셋이 된다. 불량 표본이 적으면 한 건의 예측 변화도 점수에 크게 반영되므로, 혼동행렬과 제품별 결과를 함께 보고한다.

어떤 F1인지 명확하게 기록한다

표기	의미와 주의점
불량 클래스 F1	불량 1을 양성으로 계산. 이번 과제에서 명시할 핵심 지표.
Macro F1	양품·불량 각각의 F1을 같은 비중으로 평균. 불량 F1과 다름.
Weighted F1	클래스별 표본 수로 가중 평균. 양품이 많아 양품 성능이 크게 반영됨.

F1과 함께 보고할 지표

불량 Recall, FN 개수, Precision, FP 개수, 검사 비율, 상위 10% 검사 시 Recall을 함께 제시한다. F1 공식에서 FP와 FN의 계수는 같지만, 실제 불량 유출 비용과 추가 검사 비용이 같다는 뜻은 아니다.

읽는 순서: 불량을 몇 개 놓쳤는지 → 얼마나 검사해야 하는지 → 그 균형을 F1이 어떻게 요약하는지 확인한다. 이 문서는 앞선 대화의 설명을 정리한 학습자료이며, 실제 모델 성능을 보고하지 않는다.