

사출성형 불량 예측 모델과 학습 검증 전략

Logistic Regression · Random Forest · One-Class SVM
제6회 K-인공지능 제조데이터 분석 경진대회 적용 가이드

이 문서는 세 모델의 수학적 원리와 실제 데이터 적용 절차를 연결한다. 목표는 **최종검사 이전의 불량 위험 예측, 검사 우선순위 결정, 미탐·오탐 발생조건 설명**이다. 모델 성능을 실측한 결과보고서가 아니라, 데이터 진단에 근거한 학습·검증 설계서다.

먼저 확정할 세 가지

- ① **동일한 공정 패턴은 같은 분할에 둔다.** 라벨 데이터 2,393행 중 고유 공정 패턴은 제품별 합계 1,197개다. 행을 무작위로 나누면 같은 패턴을 학습하고 다시 평가할 수 있다.
- ② **불량 확률과 이상 점수를 구분한다.** Logistic Regression과 Random Forest는 양품·불량을 함께 학습한다. One-Class SVM은 정상 영역을 학습하며, 영역 밖이라는 이유만으로 불량이 확정되지는 않는다.
- ③ **미라벨 데이터는 공통 척도 확인 후 사용한다.** 네 CSV가 각각 표준화되어 있다. 학습 데이터와 미라벨 데이터의 숫자가 같은 물리적 조건을 뜻하는지 확인하기 전에는 의사라벨 학습을 기본안으로 채택하지 않는다.

요청 항목	해당 페이지
모델별 이론과 수식	4-6
대회 데이터셋 적용과 초기 설정	2-3, 7
Data split, validation 환류와 변수 조정	8-11
Unlabeled data 활용 전략	12-13
실험 순서와 재현성 점검	14
근거 자료와 참고문헌	15

현재 단계의 권장 구성

제품별 Logistic Regression을 해석 가능한 기준 모델로, Random Forest를 비선형 비교 모델로 둔다. One-Class SVM은 별도 비교 모델이자 낯선 공정조건을 알리는 보조 신호로 사용한다. 세 모델 모두 같은 평가 행과 같은 검사 예산으로 비교한다.

작성일 2026-09-23 · 라벨은 가공 데이터 실습 기준 0=양품, 1=불량 · 공식 제출 마감 2026-10-08 23:59 [A1]. 모델 우열과 제시한 탐색값의 최적성은 아직 확인되지 않았다.

실제 데이터 진단과 해석의 한계

제품과 파일	행 수	불량 1	고유 X 패턴
CN7 labeled	1,211	17 (1.40%)	606
RG3 labeled	1,182	25 (2.12%)	591
CN7 unlabeled	35,239	미제공	28,771
RG3 unlabeled	35,941	미제공	29,707

직접 집계 [A2]. X는 24개 공정변수이며 Unnamed: 0과 PassOrFail을 제외했다. 고유 패턴은 CSV를 읽은 수치의 완전 일치 기준이다. 유사하지만 같지 않은 패턴은 별도 점검 대상이다.

중복보다 더 중요한 라벨 충돌

CN7의 11개, RG3의 25개 공정 패턴 그룹에 양품과 불량률이 함께 있다. **불량 42행 중 36행이 이 충돌 그룹에 속한다.** 같은 입력에 하나의 예측을 주는 모델로는 이 그룹의 모든 행을 동시에 맞힐 수 없다. 누락 변수, 측정 해상도, 전처리 또는 라벨 오류 가능성을 구분해야 한다.

따라서 원본 라벨을 보존하고 충돌 그룹 전체를 같은 fold에 둔다. 검증·테스트에서 충돌 행을 제거하거나 다수결로 라벨을 바꾸지 않는다. 학습 시 그룹당 총 가중치를 1로 주는 대안은 별도 실험으로 비교할 수 있지만, 주 평가에는 원래 모든 행을 남긴다.

실제 파일과 가이드북을 구분해서 읽기

24개 입력변수와 라벨 외에 시간·로트·설비 식별자가 없다. Unnamed: 0을 생산시간으로 가정하지 않는다. 현재 그룹 검증은 **새 공정 패턴에 대한 검증**이며, 미래 생산이나 새 설비에 대한 검증을 대신하지 못한다.

네 파일의 비상수 변수는 각각 평균 약 0, 표준편차 약 1이다. 가이드북 인쇄 69쪽의 코드 43도 파일별 StandardScaler 적용을 보여준다. 따라서 수치 1.5를 1.5초·1.5°C로 읽을 수 없다. 라벨 파일의 Clamp_Open_Position은 상수 0이지만 미라벨 파일에서는 변한다.

가이드북 인쇄 24쪽은 1=양품으로 표기하지만, 해당 가공 데이터의 인쇄 69쪽 실습은 **0=양품, 1=불량**으로 설명한다. 이 문서는 후자를 따른다. 제출용 데이터 명세에서 라벨 정의를 최종 확인하고, 문서 내 상충도 기록한다.

NaN 결측은 네 파일에서 발견되지 않았다. 결측이 없다는 사실은 수집·라벨·전처리의 정확성을 보장하지 않는다. 가이드북의 전체 데이터 수와 실습 예시 건수는 현재 ZIP 집계와 다르므로 현재 파일을 기준으로 한다. [A2, A3]

공통 입력 설계와 전처리

예측 시점을 먼저 고정한다

기본 시점은 사출 사이클 종료 후, 최종 품질검사 이전으로 정의한다. Cycle_Time이나 Max_Injection_Pressure처럼 사이클이 끝나야 확정되는 변수를 쓸 수 있기 때문이다. 사이클 도중 조기경보를 주장하려면 그 시점까지 관측된 변수만 사용한 별도 모델과 시간 정보가 필요하다.

변수군	예시	모델에서 확인할 관계
시간	Injection_Time, Filling_Time, Plasticizing_Time, Cycle_Time, Clamp_Close_Time	공정 진행시간과 불량 위험
위치	Cushion_Position, Plasticizing_Position, Clamp_Open_Position	계량·보압 관련 조건 변화
속도와 회전	Max_Injection_Speed, Max_Screw_RPM, Average_Screw_RPM	충전과 가소화 특성
압력	Max_Injection_Pressure, Max_Switch_Over_Pressure, Max_Back_Pressure, Average_Back_Pressure	사출·보압 전환 및 배압 조건
온도	Barrel_Temperature_1~6, Hopper_Temperature, Mold_Temperature_3~4	가열·금형 관련 조건

모든 학습 fold에서 반복할 처리

파일명으로 product를 보존하고, 입력에서 Unnamed: 0과 PassOrFail을 제거한다. 그룹 ID는 전처리 이전의 24개 X와 제품으로 만든다. 상수변수 제거, 결측 대체가 필요할 경우 그 통계, 스케일러, 변수 선택은 **현재 학습 fold만으로 fit**하고 검증에는 transform만 한다. [S8]

Logistic Regression은 학습 fold의 StandardScaler를 적용한다. Random Forest는 추가 표준화가 필수는 아니다. One-Class SVM은 정상 학습 샘플로 스케일러와 경계를 학습하는 구성을 기본으로 한다. 라벨 데이터의 상수변수는 학습 입력에서 제외하되, 미라벨에서의 변화는 별도 데이터 진단으로 남긴다.

이미 수행된 원본 파일별 표준화 이력은 새 Pipeline으로 자동 복구되지 않는다. 원단위 데이터와 기존 scaler가 확보되면, 먼저 분할하고 학습 fold에서만 표준화하는 절차로 전체를 다시 검증한다. 제품별 모델을 기본으로 두며, 표준화된 CN7·RG3를 합친 모델은 별도 가설로 검증한다.

Logistic Regression 이론과 수식

불량 여부 y 를 베르누이 확률변수로 보고, 공정변수 x 의 선형 결합을 시그모이드에 통과시켜 불량 확률을 추정한다. x 는 전처리 후 d 차원 벡터, w 는 계수, b 는 절편이다. [S1]

$$z_i = b + w^T x_i, \quad p_i = P(y_i = 1 \mid x_i) = \frac{1}{1 + e^{-z_i}}$$

$$\log \frac{p_i}{1 - p_i} = b + w^T x_i, \quad \hat{y}_i = \mathbf{1}[p_i \geq \tau]$$

다른 변수가 일정할 때 x 의 j 번째 성분이 1 증가하면 오르는 $\exp(w_j)$ 배가 된다. 표준화 입력에서 1은 표준화 단위이며 1°C가 아니다. 계수의 방향은 조건부 연관성을 나타내며 인과효과로 해석하지 않는다.

가중 로그손실과 L2 정규화

$$J(w, b) = \frac{1}{S} \sum_{i=1}^n s_i [-y_i \log p_i - (1 - y_i) \log(1 - p_i)] + \frac{\|w\|_2^2}{2SC}$$

$$S = \sum_i s_i, \quad \nabla_w J = \frac{1}{S} \sum_i s_i (p_i - y_i) x_i + \frac{w}{SC}$$

s_i 는 클래스 가중치와 샘플 가중치의 곱이다. 위 식은 절편을 정규화하지 않는 L2 구성이다. C 가 작을수록 계수 크기를 강하게 억제한다. 수치 최적화가 이 손실을 줄이는 방향으로 w 와 b 를 갱신한다. 학습된 계수와 달리 C ·가중치·입력변수는 검증으로 선택하는 설정값이다.

이번 데이터에서의 적용

제품별로 양품과 불량을 모두 사용한다. 처음에는 선형항과 L2만 사용하고, 미탐이 특정 변수 조합에 집중될 때 제한적인 제곱항·상호작용을 추가한다. 불량 수가 적으므로 모든 변수의 고차 다항식을 한꺼번에 추가하지 않는다.

가중치 없음과 `class_weight="balanced"`를 비교한다. `balanced`의 클래스 가중치는 $n/(2n_c)$ 이며 **각 학습 fold에서 계산**한다. 가중 학습 후 `predict_proba`를 실제 불량률과 동일시하지 말고 별도 확률보정 여부를 검토한다.

장점: 빠른 학습, 계수 해석, 작은 표본에서의 강한 기준선. 한계: 원래 입력에서 로그오즈가 선형이라는 가정, 상관된 변수의 계수 불안정, 비선형 경계 표현의 제약. 이 페이지의 공식은 [S1], 적용·탐색 전략은 본 데이터에 대한 제안이다.

Random Forest 이론과 수식

부트스트랩으로 뽑은 학습 표본과 매 분기에서 무작위로 선택한 후보 변수로 여러 결정트리를 학습한다. 서로 다른 트리의 예측을 평균하여 단일 트리의 변동성을 줄인다. [S2]

트리 한 개가 학습하는 분기

$$G(t) = 1 - \sum_{c \in \{0, 1\}} \pi_{t,c}^2$$

$$\Delta G = G(t) - \frac{W_L}{W_t} G(L) - \frac{W_R}{W_t} G(R)$$

π 는 노드 안의 가중 클래스 비율, W 는 샘플 가중치 합이다. 후보 변수와 절단값 중 불순도 감소 ΔG 가 큰 분기를 선택한다. `max_depth`는 분기의 깊이를, `min_samples_leaf`는 말단 노드의 최소 행 수를 제한한다.

숲의 불량 확률

$$\hat{p}_{RF}(x) = \frac{1}{B} \sum_{b=1}^B \hat{p}_b(y = 1 | x)$$

B 는 트리 수다. 각 트리는 x 가 도달한 말단 노드의 가중 불량 비율을 출력한다. `scikit-learn`의 `predict_proba`는 이 확률들을 평균한다. 따라서 단순히 “불량으로 투표한 트리의 비율”과 항상 같지는 않다.

이번 데이터에서의 적용

제품별 양품·불량을 함께 학습한다. 초기에는 깊이 3~6과 leaf 최소 5~20행처럼 비교적 단순한 트리부터 시작한다. 트리 수를 늘리는 것은 평균의 안정성을 높이지만, 동일 패턴의 중복과 라벨 충돌을 해결하지는 못한다.

불균형 대응은 가중치 없음과 `balanced_subsample`을 비교한다. 후자는 각 트리의 부트스트랩 표본에서 클래스 가중치를 계산한다. 중복이 많은 데이터에서는 leaf 행 수가 독립적인 공정 패턴 수와 다르다는 점도 기록한다.

OOB 점수를 주 검증으로 쓰지 않는다. 한 중복 행이 OOB여도 같은 X 를 가진 다른 행이 트리 학습에 들어갈 수 있다. 주 평가는 고정된 그룹 분할로 수행하고, 변수 해석은 검증 fold의 permutation importance와 조건별 오류를 함께 본다.

장점: 비선형성과 변수 간 상호작용을 자동 표현한다. 한계: 희귀 불량률의 작은 leaf 암기, 확률의 불안정, 관측 범위 밖 일반화의 제약. 중요도가 높아도 원인변수라고 단정하지 않는다. 정의·구현은 [S2], 검증 설계는 본 데이터에 대한 제안이다.

One-Class SVM 이론과 수식

정상 데이터의 분포가 차지하는 영역을 학습한다. RBF 커널은 원래 공간의 거리를 이용하여 비선형 경계를 만든다. 정상 영역 밖의 샘플은 새로운 조건 또는 이상 후보이며, 품질불량과 반드시 일치하지 않는다. [S3, S4]

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

$$\min_{w, \rho, \xi} \frac{1}{2} \|w\|^2 + \frac{1}{vn} \sum_{i=1}^n \xi_i - \rho$$

$$w^T \phi(x_i) \geq \rho - \xi_i, \quad \xi_i \geq 0$$

ϕ 는 커널에 대응하는 특징변환, ρ 는 경계의 위치, ξ 는 경계 밖으로 벗어나는 것을 허용하는 여유변수다. 여기서 n 은 정상 학습 샘플 수다. 모델은 복잡한 경계를 억제하면서 대부분의 정상 샘플을 포함하도록 학습한다.

$$\min_{\alpha} \frac{1}{2} \alpha^T K \alpha, \quad 0 \leq \alpha_i \leq \frac{1}{vn}, \quad \sum_i \alpha_i = 1$$

$$f(x) = \sum_i \alpha_i K(x_i, x) - \rho, \quad s(x) = -f(x)$$

α 가 0보다 큰 샘플이 support vector다. scikit-learn의 decision_function은 정상일수록 크므로, 비교용 이상 점수는 부호를 반대로 한 s 를 쓴다. 기본 predict는 정상 +1, 이상 -1이며, 불량 후보 1로 사용할 때는 명시적으로 변환한다.

ν 와 γ 를 잘못 해석하지 않기

ν 는 실제 불량률이 아니다. 표준 최적화 해에서 학습 오류 비율의 상한과 support vector 비율의 하한을 제어한다. γ 가 커지면 좁고 복잡한 경계가 생기기 쉬워진다. 둘 다 라벨이 있는 검증 데이터로 선택하되, 경계의 fit에는 정상 학습 데이터만 넣는다.

알려진 불량과 같은 X 를 가진 정상 학습 행을 경계 학습에서 제외하는 대안도 비교한다. 이 제외 판단은 해당 학습 fold의 라벨만 사용한다. 검증·테스트의 충돌 그룹은 그대로 평가한다.

이상 점수에 sigmoid를 단순 적용해도 불량 확률이 되지 않는다. 불량 확률이 필요하면 독립적인 라벨 예측으로 보정해야 한다. 이번 구성에서는 LR/RF가 확률 예측을 담당하고 OCSVM은 이상 점수 역할을 유지해도 된다.

모델별 학습 구성과 탐색 범위

아래 값은 탐색의 출발점이며 최적값이나 검증된 성능이 아니다. 첫 실험은 제품별 모델로 수행한다. 동일 모델 내 입력·하이퍼파라미터·가중치·임계값의 변경 효과를 분리해 기록한다.

모델	초기 구성	작은 탐색 범위
Logistic Regression	학습 fold 표준화 L2, solver=lbfgs max_iter=2,000	C: 0.01, 0.1, 1, 10 class_weight: None, balanced 먼저 원변수만 사용
Random Forest	n_estimators=500 bootstrap=True 고정 random_state	max_depth: 3, 6, None min_samples_leaf: 5, 20 max_features: sqrt, 0.7 가중치: None, balanced_subsample
One-Class SVM	kernel=rbf 정상 학습 X로 fit 정상 학습 기준 스케일링	nu: 0.01, 0.03, 0.05, 0.10 gamma: 0.1/d, 1/d, 10/d d는 상수 제거 후 변수 수

비교 예산을 통제한다

LR은 8개, OCSVM은 12개 기본 조합을 평가할 수 있다. RF는 표의 24개 조합을 모두 쓰거나, 실행시간에 맞춰 사전 고정한 12개를 먼저 비교한다. 그 뒤 가장 중요한 한 축만 좁힌다. 탐색 횟수가 많은 모델이 우연히 유리해지는 것을 막기 위해 시도한 조합 수를 기록한다.

정상 데이터만 쓰는 OCSVM의 평가도 지도 평가다

학습에 불량을 넣지 않는 것과, 불량 검증 라벨을 쓰지 않는 것은 다르다. OCSVM의 nu·gamma·판정 임계값은 LR/RF와 동일한 검증 행의 양품·불량으로 평가한다. 정상만 있는 검증셋으로는 불량 재현율을 비교할 수 없다.

가중치와 증강을 한 번에 겹치지 않는다

첫 비교에는 SMOTE나 무작위 복제를 쓰지 않는다. 이미 중복과 라벨 충돌이 있고, 소수 불량 사이를 보간한 값이 가능한 공정조건이라는 근거도 없다. 이후 시도하더라도 학습 fold 안에서만 수행하고, 검증·테스트의 클래스 비율은 바꾸지 않는다.

제품별 모델의 장점은 제품 차이를 분리하는 것이다. 단점은 CN7의 불량이 17행뿐이라는 점이다. 통합 모델+제품 식별자를 보조 실험으로 비교할 수 있으나, 파일별 표준화 때문에 같은 수치가 같은 물리조건이라는 가정은 금지한다. [S1-S4]

Data split과 validation 설계

기본안은 잠근 테스트 20%와 개발셋 80%

그룹 ID는 **제품 + 24개 X의 동일 패턴**으로 만들며 y를 포함하지 않는다. 제품×라벨 조합을 층화 대상으로 사용해 StratifiedGroupKFold 5개 fold를 만들고, 사전에 정한 첫 fold를 최종 테스트로 잠근다. 나머지 개발셋에서 3-fold 그룹 교차검증을 수행한다. [S5]

구분	CN7 양품 / 불량	RG3 양품 / 불량	전체 행 수
개발셋	956 / 13	926 / 20	1,915
잠근 테스트	238 / 4	231 / 5	478
개발 CV 검증 fold 1	318 / 4	309 / 7	638
개발 CV 검증 fold 2	318 / 5	309 / 7	639
개발 CV 검증 fold 3	320 / 4	308 / 6	638

위 분할은 실제 CSV에서 구성 가능함을 확인한 예시다. scikit-learn 1.8.0, shuffle=True, random_state=42, CN7 다음 RG3 순서로 결합, 각 단계의 첫 split 기준. 모델은 아직 학습하지 않았다. 최종 구현에서는 행별 split manifest를 저장하여 버전·순서 변화에도 고정한다.

각 데이터의 권한을 구분한다

학습 fold: 전처리 fit, 변수 선택, 모델 계수·트리·경계 학습, 허용된 미라벨 의사라벨 생성에 사용한다.

검증 fold: AP·F1·검사예산별 성능, 오류 조건, 하이퍼파라미터·임계값 선택에 사용한다.

잠근 테스트: 모든 선택이 끝난 최종 파이프라인에 한 번만 사용한다. 결과를 본 뒤 개선하면 더 이상 독립 테스트가 아니다.

소수 불량 때문에 생기는 불확실성

예시 테스트의 불량률은 9행이다. 한 건을 더 놓치면 전체 재현율이 약 11.1%p, CN7에서는 25%p 변한다. 점수 한 개로 우열을 단정하지 말고 개발 CV의 fold별 값·평균·범위와 함께 제시한다. 그룹 단위 부트스트랩 구간도 표본이 적다는 한계를 병기한다.

분할 seed는 점수가 잘 나오는 값으로 바꾸지 않는다. 첫 설계 때 클래스 존재와 그룹 겹침만 확인한다. 안정성은 사전 지정한 추가 seed 2개로 개발셋 CV만 반복한다. 테스트는 그대로 둔다.

시간·로트가 확보되면 실제 생산단위를 그룹으로 사용하고 미래 구간을 holdout하는 검증으로 바꾼다. 완전 일치 그룹은 로트를 대체하지 못하며, 유사 패턴의 누수 가능성도 남는다.

검증 결과를 학습에 환류하는 절차

Validation 환류는 검증 행을 학습에 계속 섞는 것이 아니라, 검증에서 발견한 문제를 다음 실험의 설정 변경으로 연결하는 과정이다. 검증 라벨로 모델 계수나 트리를 직접 fit하지 않는다.

단계	실행 내용	남길 기록
1. 기준선	고정 fold로 세 모델을 학습·예측한다. OCSVM은 정상 학습 행만 사용한다.	행 ID, group, product, y, fold, score, 설정값
2. 원인 진단	미탐·오탐을 제품·변수 구간·충돌 그룹으로 나누어 확인한다.	분모·오류 건수, 반복되는 조건
3. 한 축 변경	입력변수, 규제/복잡도, 가중치, 임계값 중 한 가지를 바꾼다.	변경 이유와 가설
4. 재검증	동일 fold로 비교한다. AP와 동일 검사예산의 재현율을 함께 본다.	fold별 차이, 최악 제품 성능
5. 선택·동결	작은 개선보다 재현성과 단순성을 우선한다. 변수·모델·보정·임계값을 고정한다.	최종 설정과 선택 근거
6. 최종 평가	개발셋으로 최종 파이프라인을 구성하고 잠근 테스트를 한 번 평가한다.	혼동행렬과 한계, 재실험 금지

과적합 여부에 따른 조정

학습 성능만 높을 때: 중복 누수부터 확인한다. LR은 C를 낮추고 변수 수를 줄인다. RF는 깊이를 줄이고 min_samples_leaf를 높인다. OCSVM은 gamma를 낮춰 더 부드러운 경계를 검토한다.

학습·검증 모두 낮을 때: 라벨 방향, 예측 시점, 입력 정보의 충분성을 먼저 확인한다. 그다음 제한적인 비선형 변수나 모델 복잡도 증가를 시험한다. 충돌 라벨은 복잡한 모델만으로 해소되지 않는다.

미탐이 많을 때: 임계값을 낮춰 검사량·오탐이 얼마나 늘어나는지 먼저 측정한다. 순위 자체가 나쁘면 변수 또는 학습 가중치를 조정한다. 임계값 변경은 AP를 개선하지 않는다는 점을 구분한다.

검증을 반복해 볼수록 개발셋에도 과적합된다. 실험 수를 제한하고, 사람의 오류분석을 포함한 모든 선택은 개발셋 안에서 끝낸다. 논문 수준의 튜닝 절차 자체를 평가하려면 outer 3-fold / inner 3-fold 중첩 그룹 CV를 대안으로 사용하되 두 결과를 독립 실험처럼 중복 계산하지 않는다.

평가지표와 검사 임계값

양성은 불량 1이다. TP는 잡아낸 불량, FN은 놓친 불량, FP는 양품을 불량 후보로 올린 경우다. 전체 양품 예측의 정확도도 약 98.24%이므로 Accuracy만으로 모델을 평가하지 않는다.

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad F_1 = \frac{2TP}{2TP + FP + FN}$$

$$AP = \sum_k (R_k - R_{k-1})P_k, \quad F_2 = \frac{5PR}{4P + R}$$

주 순위 지표는 Average Precision(AP), 공지 대응 분류 지표는 F1로 둔다. AP는 recall 증가량으로 precision을 가중한 값이며, 사다리꼴 적분 PR-AUC와 구현값이 다를 수 있으므로 이름을 정확히 적는다. F2는 재현율에 더 무게를 주는 보조 지표다. [S9]

검사 우선순위는 같은 검사 예산에서 비교한다

$$\text{Recall}@q = \frac{\sum_{i \in \text{Top}[qN]} y_i}{\sum_{i=1}^N y_i}$$

예를 들어 q=5%, 10%, 20%를 사전 지정하고 높은 위험도 순으로 검사할 때 잡히는 불량 비율을 비교한다. 검사량과 양품 오경보 수를 같이 제시한다. 점수가 같은 패턴은 라벨을 보지 않는 고정 ID 순서 등으로 tie-break하고 그 규칙을 저장한다. 10% 검사는 제안 시나리오이며 공식 제한이 아니다.

임계값은 개발셋의 미학습 예측으로 정한다

LR/RF는 해당 행을 학습하지 않은 out-of-fold(OOF) 예측을 모은다. 임계값 후보마다 F1과 검사량을 계산하고, 예산 제약 아래 재현율이 높은 값을 선택한다. 선택에 사용한 OOF 성능은 개발 성능이며 최종 성능은 잠근 테스트에서 계산한다.

OCSVM의 raw 점수는 fold·제품마다 척도가 달라질 수 있다. AP와 Top-q는 fold·제품 안에서 먼저 계산한다. 공통 임계값이 필요하면 정상 학습 점수의 경험 누적분포 F_0 로 $u=F_0(s)$ 를 만들어 상대적 이상 백분위로 비교하는 방안을 검증한다. u 는 확률이 아니며, 학습 기준의 낙관성은 검증에서 확인한다.

$$\text{Cost}(\tau) = c_{FN}FN(\tau) + c_{FP}FP(\tau), \quad \tau^* = \frac{c_{FP}}{c_{FN} + c_{FP}}$$

마지막 임계값 공식은 정확히 보정된 확률, 일정한 오류비용, 별도 검사 예산 제약이 없는 이진 의사결정에만 적용된다. 실제 비용은 미제공이므로 가정별 민감도 분석으로 제시한다. [S9]

변수 조정과 오류 설명 및 확률보정

추가할 변수는 공정 해석과 관측 가능성으로 제한한다

후보	현재 CSV에서의 의미	검증 방법
선택 변수의 제공항	표준화값 양·음 방향의 이탈을 표현한다. 물리적인 에너지·압력 제공이 아니다.	LR에 소수만 추가, OOF AP 변화 확인
압력×시간 상호작용	두 표준화 변수의 결합 효과. 실제 압력·시간의 곱과 구별한다.	원변수 유지 후 추가, fold별 안정성 확인
온도 변수군의 평균·산포	각 채널의 상대적 표준화 패턴 요약이다. 실제 온도 편차 °C가 아니다.	온도군 공동 제거 실험, 오류조건 변화 확인
직전 사이클 차이·이동평균	시간 순서가 검증되지 않아 현재는 사용하지 않는다.	타임스탬프 확보 후 과거 값만 이용

오류분석을 다음 실험으로 연결하기

입력 구간 경계는 학습 데이터의 분위수로 정한다. 검증에서 구간별 전체 행 수·실제 불량 수·FN·FP를 보고하고, 표본 1~2건의 패턴을 일반 법칙으로 쓰지 않는다. 총돌 그룹과 비총돌 그룹의 결과는 분리해 설명하되 전체 성능도 유지한다.

LR은 계수 방향이 fold마다 바뀌는지 확인한다. RF는 검증 데이터의 permutation importance를 사용하되 상관변수끼리 중요도가 분산될 수 있으므로 변수군 제거도 비교한다. OCSVM은 정상 범위를 벗어난 변수와 이상 점수를 함께 설명한다. 어느 경우도 중요도를 불량량의 인과적 원인으로 단정하지 않는다.

확률을 현장 의사결정에 쓰려면

LR/RF의 가중 학습은 확률을 왜곡할 수 있다. 보정 후보는 소수 불량에 비교적 단순한 sigmoid로 제한하고, Brier score와 신뢰도 곡선을 함께 확인한다. 많은 데이터를 요구하는 isotonic은 기본안으로 쓰지 않는다. [S6]

보정 검증에서는 검증 fold를 완전히 떼고, 남은 학습 fold 내부의 그룹 교차검증으로 OOF 점수를 만든 뒤 보정기를 fit한다. base 모델도 그 학습 fold로만 학습하여, 보정까지 마친 예측을 바깥 검증 fold에 적용한다. 마지막에는 보정기를 전체 개발 OOF에 fit하고 base 모델을 개발셋에 재학습한다. 재학습으로 점수 척도가 달라질 가능성까지 잠근 테스트에서 확인한다.

불량 33행인 개발셋에서 제품별 보정은 매우 불안정할 수 있다. 보정 전후를 모두 보고하고, 근거가 약하면 숫자를 “불량 확률”보다 “위험 점수”로 표현한다. 제품 간 통합 검사 순위는 확률의 비교 가능성을 확인하기 전에는 제품별 예산 배분으로 운영한다.

Unlabeled data를 쓰기 전의 통과 조건

미라벨 71,180행은 라벨 데이터의 약 29.7배다. 양이 많다는 이유만으로 이득이 보장되지 않는다. 먼저 이 데이터가 추가 학습용인지 공식 테스트용인지, 학습에 사용해도 되는지를 과제 명세에서 확인한다. [A1, A2]

가장 큰 장애물은 파일마다 다른 표준화 기준이다

$$Z_{L,j} = \frac{x_j - \mu_{L,j}}{\sigma_{L,j}}, \quad Z_{U,j} = \frac{x_j - \mu_{U,j}}{\sigma_{U,j}}$$

같은 z라도 원래 x가 다를 수 있다. 특히 표준편차가 서로 다르면 거리 기반 OCSVM의 경계와 LR/RF의 절단 기준을 그대로 옮기는 근거가 약해진다. 이미 표준화한 두 파일을 다시 함께 표준화해도 잃어버린 원단위는 복구되지 않는다.

확인 상태	가능한 활용	금지할 해석
원단위 또는 기준 scaler 확보	공통 좌표로 복구한 뒤, 각 학습 fold 기준의 scaler를 L과 U에 적용한다. 의사라벨·정상영역 보강을 비교한다.	현재 전체 데이터를 먼저 fit한 전처리를 새 검증에도 재사용
기준 불명인 현재 상태	파일별 분포·상관·중복 점검, U 내부 이상 순위, 확인이 필요한 샘플 목록을 만든다.	L 모델의 U 예측을 검증된 불량 확률이라고 주장
공식 테스트로 지정된 U	허용된 추론만 수행한다. 학습 허용 여부는 명세에 따른다.	무단 self-training 후 독립 테스트 성능으로 제시

공통 좌표가 확보된 다음에도 확인할 것

제품, 센서 정의, 공정 시점, 수집 범위가 같은지 검토한다. L과 U의 원단위 분위수·상관관계·정상영역 밖 비율을 비교한다. 소스가 L인지 U인지 예측하는 보조 진단도 가능하지만, 높은 구분 성능은 분포 차이의 신호일 뿐 그 원인을 확정하지는 못한다.

미라벨 중 검증·테스트 행과 동일한 생산 건 또는 같은 그룹은 학습용 U에서 제외한다. 공통 좌표와 원본 ID가 없으면 파일 간 중복을 완전히 확인할 수 없다는 한계를 남긴다.

기본 제출 후보는 U 미사용 모델이다. U를 사용한 모델은 같은 고정 검증에서 실제 개선과 오류 조건의 악화 여부를 확인한 경우에만 채택한다. 현재 상태의 U 내부 이상 탐지는 품질불량 탐지 성능으로 평가할 수 없다.

Unlabeled data의 단계별 활용 전략

전략 A LR와 RF의 보수적인 의사라벨 학습

12쪽의 공통 좌표·사용허용 조건을 충족한 경우에만 시작한다. 각 학습 fold의 라벨 데이터로 LR·RF를 학습하고, 학습 fold 내부 교차적합으로 신뢰도를 점검한다. 검증 fold의 라벨이나 예측을 의사라벨 학습에 섞지 않는다.

self-training은 초기 모델의 오류를 증폭할 수 있다. [S7]

$$U_+ = \{u : p_{LR}(u) \geq t_+, p_{RF}(u) \geq t_+\}$$

$$U_- = \{u : p_{LR}(u) \leq t_-, p_{RF}(u) \leq t_-\}$$

두 모델의 일치는 독립적인 정답 증거가 아니다. 예시로 $t_+=0.95$, $t_-=0.01$ 을 시험할 수 있으나 확률보정과 inner 검증에서 신뢰도가 확인되지 않으면 이 수치를 사용하지 않는다. 매우 불균형한 데이터에서 0.95라는 값만으로 높은 정밀도가 보장되지 않는다.

$$J = \sum_{i \in L} w_i \ell(y_i, p_i) + \lambda \sum_{j \in U_{sel}} v_j \ell(\tilde{y}_j, p_j) + \Omega$$

참 라벨을 우선한다. 예를 들어 $\lambda=0.1$ 부터 시작하고 의사라벨 전체 가중치 합을 참 라벨 가중치 합의 20% 이하로 제한한다. 제품·클래스별 유입량에도 상한을 둔다. LR에서는 가중치 규모가 C와 상호작용하므로 총 가중치 기준을 고정한다. 1회 추가 학습을 기본으로, 최대 2회까지만 비교한다.

전략 B One-Class SVM의 정상영역 보강

U 전체를 정상이라고 넣지 않는다. 참 정상과 가까우며 LR·RF 모두 저위험으로 판단한 후보를 소량 추가한다. 참 정상만 학습한 경계와 반드시 비교한다. 반복 패턴은 줄이고 정상 후보의 다양성을 유지한다. 선택 후보가 실제 정상이라는 보장은 없으므로 미탐 증가 여부가 핵심 중단 기준이다.

대규모 RBF OCSVM은 계산량이 커질 수 있다. 정상 후보는 예컨대 제품당 2,000~5,000개 이하부터 시험하되, 이 수치는 성능 기준이 아닌 실행 예산이다. 현재 파일별 척도가 복구되지 않았다면 U 단독 모델은 U 내부 점검 순위로만 사용한다.

전략 C 실제 검사를 통한 라벨 확보

검사가 가능한 경우 모델 간 불일치, OCSVM 고이상, 임계값 부근에서 대표 샘플을 골라 실제 품질을 확인한다. 일부는 무작위 검사하여 편향을 점검한다. 얻은 라벨의 출처를 기록하고, 잠근 테스트에 속한 샘플은 학습에 추가하지 않는다.

U가 도움 되는지는 U 미사용 / 의사라벨 / 정상영역 보강의 ablation으로 비교한다. 검증 AP 또는 같은 검사예산의 재현율이 악화되거나 특정 제품의 미탐이 늘면 채택하지 않는다. 가중치·상한·임계값은 제안값이며 실측 결과가 아니다.

실험 순서와 재현 가능한 산출물

실험	바꾸는 항목	판단 기준
E0 데이터 감사	라벨·24개 변수·중복·충돌·split 고정	그룹 교집합 0, 제품별 양성 존재
E1 세 모델 기준선	U 미사용, 원변수, 고정 fold	제품별 AP·F1·Recall@10%
E2 학습 설정	규제·트리 복잡도·nu/gamma·가중치	평균과 최악 fold 개선
E3 변수·충돌 대응	소수 파생변수, 그룹 가중치, OCSVM 정상 학습 그룹 필터	전체 평가 유지, 충돌/비충돌 별도 비교
E4 운영 설정	확률보정·임계값·검사 예산	검사량 대비 재현율, 확률 신뢰도
E5 U 활용	조건 충족 시 의사라벨·정상 보강	E4 대비 ablation, 누수·오류 증가 없음
E6 최종 평가	설정 동결 후 개발셋 재학습	잠근 테스트 1회 평가

실행 절차의 핵심

- ① 원본 행 ID·제품·그룹·split을 저장한다.
- ② 동일 split으로 세 모델을 돌리고, 학습 fold의 전처리와 모델을 함께 보존한다.
- ③ 검증 예측을 모아 오류분석과 설정 변경을 기록한다.
- ④ U 사용 시 fold마다 teacher와 의사라벨을 새로 만든다.
- ⑤ 최종 변수·설정·보정·임계값·제품별 예산을 동결한다.
- ⑥ 개발셋으로 최종 파이프라인을 학습하고 잠근 테스트를 평가한다.

결과표에 반드시 남길 값

모델·제품·fold·양품/불량 수·AP·F1·Precision·Recall·FP·FN·검사비율·Recall@5/10/20%·학습시간·추론시간을 기록한다. 보정 모델에는 Brier score를 추가한다. 모델별 raw 점수를 비교 가능한 확률처럼 한 열에 섞지 않는다.

제출 패키지

README, requirements.txt 또는 environment.yml, 학습·추론 실행코드, 학습 데이터, 예측결과를 함께 준비한다. 변수 순서, scaler, product routing, 클래스 방향, 보정기, 임계값, tie-break 규칙까지 저장한다. 공식 예측 파일 형식은 별도 확인이 필요하다. [A1]

이 문서는 데이터 진단과 분할 구성만 확인했다. 세 모델의 학습·검증 점수 또는 U 활용 성능은 생성하지 않았다. 마지막 테스트를 본 뒤 전체 라벨로 제출 모델을 다시 학습한다면, 보고된 점수는 재학습 전 파이프라인의 평가라는 점을 구분해 적는다.

근거 자료와 참고문헌

첨부자료에 근거한 사실, 공식 알고리즘 설명, 본 데이터에 대한 제안을 구분했다. 링크는 2026-09-23 확인 기준이며, 구현에서는 실제 설치 버전을 고정한다. 본 문서의 분할 확인 환경은 scikit-learn 1.8.0이다. 온라인 stable 문서와 버전이 다를 수 있다.

첨부자료

[A1] 「제6회 K-인공지능 제조데이터 분석 경진대회 과제공개(일반국민,대학(원)생).hwp」. 사출성형 과제, 평가표, 제출물·마감 안내. 준비 가이드보다 이 공식 과제공개 문서를 우선했다.

[A2] 「1. 사출성형기 AI 데이터셋.zip」. moldset_labeled_cn7.csv, moldset_labeled_rg3.csv, moldset_unlabeled_cn7.csv, moldset_unlabeled_rg3.csv. 행 수·라벨·중복·충돌·표준화 통계 및 분할 구성은 직접 확인했다.

[A3] 「04. Guidebook_Molding-압축됨.pdf」. 인쇄 20-21쪽: 가공 데이터 변수 설명. 인쇄 24쪽: 라벨 표기. 인쇄 69쪽(PDF 70페이지): 0/1 라벨 설명과 파일별 StandardScaler 코드. 원본·가공 데이터의 기술이 혼재하므로 실제 파일과 대조했다.

[A4] 「KAMP_제조AI경진대회_준비가이드.docx」. 사전 준비·도메인·재현성 전략을 참고했다. 예상 일정 및 대회 범위는 [A1]로 대체했다.

공식 알고리즘 문서 및 원 논문

[S1] scikit-learn · Logistic regression
시그모이드, 가중 로그손실, 정규화.

[S2] scikit-learn · RandomForestClassifier
트리 분기·가중치·확률 평균.

[S3] scikit-learn · OneClassSVM
nu·gamma·decision_function 정의.

[S4] Schölkopf et al. (1999) · Support Vector Method for Novelty Detection
원 논문 2절의 primal-dual 목적함수.

[S5] scikit-learn · StratifiedGroupKFold
그룹 중복 방지와 근사적 클래스 총화.

[S6] scikit-learn · Probability calibration
독립 예측을 사용한 확률보정.

[S7] scikit-learn · Semi-supervised learning
self-training과 분포 가정.

[S8] scikit-learn · Common pitfalls and recommended practices
전처리 누수 방지와 Pipeline.

[S9] scikit-learn · Metrics and scoring
Precision·Recall·F-score·AP 정의.

데이터 출처: 중소벤처기업부, Korea AI Manufacturing Platform(KAMP), 사출성형기 AI 데이터셋, KAIST 및 수행기관, 2020.12.14. 정식 보고서에서는 가이드북 첫 페이지의 출처 표기 양식을 확인하여 적용한다.